

KI-basierte IGRT mit 2D-bildgeführtem Dose Tracking täglicher Conebeam-CTs zur Bewertung der Füllung von Rektum und Harnblase bei definitiver Radiotherapie des Prostatakarzinoms

Peter Rhone, Dipl.-Phys.¹, Saskia Spautz, MSc^{2,3,*},
Annika Schlamann, MD^{2,3}, Thomas Kuhnt, MD, Prof.^{2,3},
Franziska Nägler, MD^{2,3,**}

¹Klinik für Strahlentherapie und Radioonkologie, Heinrich-Braun-Klinikum Zwickau,

²Klinik und Poliklinik für Strahlentherapie, Universitätsklinikum Leipzig

³Mitteldeutsches Krebszentrum (CCCG), Partnerstandort Leipzig

*geteilte Erstautorschaft **Seniorautorin

2. Oktober 2025

Zusammenfassung

Hintergrund: Es wird eine schnelle Methode zur automatischen Erkennung von Harnblase und Rektum in täglichen Cone-Beam-CTs (kV-CBCTs) für die bildgesteuerte Strahlentherapie (IGRT) vorgestellt.

Methoden: Mediale sagittale Schnitte wurden mittels künstlicher Intelligenz (KI) segmentiert, um die Füllungszustände von Rektum und Harnblase bei der definitiven Radiotherapie des Prostatakarzinoms zu bewerten.

Ergebnisse: Das Modell wurde mit Daten von 131 Patienten trainiert und validiert mit jeweils 5 kV-CBCTs pro Patient. Die Ergebnisse zeigen eine hohe Segmentierungsleistung mit mittleren Dice-Werten von $0,9149 \pm 0,0852$ für die Harnblase und $0,7848 \pm 0,1641$ für das Rektum sowie Hausdorff-Distanzen von $9,1419 \pm 9,0216$ px (Harnblase) und $11,5230 \pm 10,5643$ px (Rektum).

Zusammenfassung: Die KI-basierte Methode kann die Überprüfung von Organfüllung effektiv und schnell automatisieren und bietet Potenzial zur Verbesserung der Behandlungsqualität und Effizienz in der IGRT.

Schlüsselworte: Segmentierung, Risikoorgane, Deep Learning, Medizinische Bildgebung, Cone-Beam-CT, CBCT, Strahlentherapie, Bildgesteuerte Strahlentherapie, Künstliche Intelligenz

1 Einleitung

Bei der definitiven Bestrahlung von Prostatakarzinomen niedrigen und mittleren Risikos kann eine perkutane Radiotherapie in Normfraktionierung, moderater Hypofraktionierung oder Ultrahypofraktionierung angewendet werden (???). Dabei wird eine Gesamtdosis in tägliche Fraktionen verabreicht.

Interfraktionelle Variabilität durch Änderungen der Füllungszustände oder Organbewegungen im Beckenbereich kann Organe at Risk (OARs) wie Harnblase und Rektum unerwünscht hohen Dosen aussetzen, was die akute oder chronische Toxizität erhöhen kann (??).

Um diese Toxizitäten zu minimieren, ist ein zentraler Schritt in der modernen Strahlentherapie die Verifizierung der genauen Position der umliegenden Risikoorgane (OARs) vor jeder Fraktion mittels bildgesteuerter Strahlentherapie (IGRT) (??). Es gibt verschiedene Methoden zur IGRT, z. B. Cone-Beam-CTs (CBCT) oder in die Prostata implantierte Fiducials (Goldmarker) in Kombination mit planaren Röntgenbildern (?). Die Verifizierung der OAR-Füllungszustände ist jedoch nur mit CBCT möglich. Damit können variierende Füllungen und Bewegungen berücksichtigt und korrigiert werden, etwa eine unzureichend gefüllte Harnblase oder ein luftgefülltes Rektum, um das Einhalten von Dosis-Constraints wie $V_{65} < 50\%$ für die Harnblase sicherzustellen (?).

Online-adaptive Strahlentherapie passt täglich diese Veränderungen an, erfordert jedoch erheblichen Zeit- und Personalaufwand (15–35 Minuten pro Fraktion mit Facharzt und Medizinphysikexperten), was in Hochdurchsatz-Kliniken kaum umsetzbar ist (?). Häufig wird daher nur ein Offline-Review durchgeführt, bei dem Abweichungen erst nachträglich erkannt werden.

Inspiziert von Fortschritten in der medizinischen Bildsegmentierung, entwickeln wir eine KI-basierte Methode zur Teilautomatisierung der online-adaptiven Therapie, um die Füllung der Risikoorgane in täglichen CBCT-Aufnahmen effizienter zu überwachen und die Behandlungsqualität zu verbessern (?).

2 Methoden

Zwischen dem 01.07.2019 und dem 31.01.2024 wurden retrospektiv 131 Patienten mit Prostatakarzinom niedrigen bis mittleren Risikos ausgewählt, die eine definitive, moderat hypofraktionierte Radiotherapie (25 Fraktionen mit simultan-integriertem Boost, 58–68 Gy) erhielten, in Anlehnung an das Schema von (?). Einschlusskriterien waren cT1a–cT2b, $PSA \leq 20 \text{ ng/ml}$ und Gleason-Score ≤ 7 ; Patienten mit Hochrisikoprofil oder Fernmetastasen wurden ausgeschlossen. Eine schriftliche Einwilligung zur anonymen Datenverwendung liegt vor.

Für jeden Patienten wurden ein Planungs-CT (PL-CT) und 5 kV-CBCTs aus dem RayStation-System (Versionen 10B–12A) anonymisiert extrahiert (?). Strukturen

(Harnblase, Rektum) wurden manuell von einem Medizininphysiker konturiert und von einem Facharzt überprüft. Ein selbst entwickeltes Python-Programm (*sqlite_dicom2.py*) (?) konvertierte DICOM-Daten in Volumina, extrahierte fünf mediale sagittale 2D-Schnitte pro kV-CBCT – zentral durch die Symphyse sowie je zwei links und rechts – und erstellte Binärmasken mittels des Point-in-Polygon-Algorithmus, um präzise Konturen für Strukturen zu generieren, die die Schnittebene mehrfach durchschneiden, wie es häufig beim Rektum der Fall ist (?). Die Ausgaben (Patienten-ID, DICOM-Serie, Schnitte, Masken, Schnittnummer) wurden in eine SQLite-Datenbank gespeichert. Ein zweites Programm (*sqlite_viewer.py*) (?) ermöglichte visuelle Kontrolle und Datenbereinigung.

Bilder wurden vorverarbeitet: ungewöhnliche Bildgrößen (z.B. 85x512 Pixel) wurden ausgeschlossen, da sie auf abweichende kV-CBCT-Protokolle zurückzuführen waren und nur die Standardgröße (88x512 Pixel) beibehalten wurde, um anatomische Details zu erhalten. Die Pixelintensitäten wurden von den gespeicherten Werten (0–8000) auf $[0, 1]$ normalisiert, indem durch den Maximalwert (8000) dividiert wurde (?).

Insgesamt entstanden 3508 Bilder für die Harnblase (129 Patienten) und 3311 Bilder für das Rektum (128 Patienten), basierend auf 5 sagittalen Schnitten pro kV-CBCT.¹

2.1 Kreuzvalidierungsdesign

Um eine robuste Abschätzung der Generalisierbarkeit zu gewährleisten und Datenlecks durch patientenübergreifende Abhängigkeiten auszuschließen, wurde die Datenbank erst in Trainings- (80%) und Validierungssets (20%) aufgeteilt, streng auf Patientenebene, um klinische Realbedingungen abzubilden, unter denen das Modell auf vollständig neue Patienten angewendet wird. Die 129 Patienten der Harnblasendatenbank und 128 Patienten der Rektumdatenbank wurden aufgeteilt in Trainings- (80%) und Validierungssets (20%). Für die Harnblase ergab das Trainingsset 103 Patienten (2808 Bilder) und das Validierungsset 26 Patienten (707 Bilder). Für das Rektum waren es 102 Patienten im Trainingsset (2646 Bilder) und 26 Patienten im Validierungsset (665 Bilder).

Eine **5-fache patientendisjunkte Kreuzvalidierung** wurde auf dem Trainingsset durchgeführt. Die Trainingspatienten wurden jeweils zufällig in fünf disjunkte Teilmengen partitioniert, wobei durch **Stratifizierung nach Organvolumen** sichergestellt wurde, dass alle Füllungszustände in jedem Fold proportional vertreten waren. T-Test-Analysen bestätigten für alle Folds keine signifikanten Volumenunterschiede zwischen Trainings- und Validierungssets ($p > 0.05$).

Zur Vermeidung von Verzerrungen durch nicht-informative Samples wurden vor der Modellierung alle Bilder mit leeren GT-Masken ($\sum \text{Maske} = 0$) aus den

¹Manipulierte Bildzahlen aufgrund von Datenbereinigung: Einige Patienten hatten weniger als 5 nutzbare CBCTs oder Schnitte aufgrund unvollständiger Strukturen.

Datensätzen entfernt - wenn etwa das Organ nicht im Bild sichtbar war.

2.2 Modelltraining und Evaluation

Ein U-Net-basiertes Convolutional Neural Network (CNN) (?) wurde mit PyTorch trainiert, um kV-CBCT-Bilder zu segmentieren (?). Das Modell verarbeitet mittelsagittale CT-Schnitte (88x512 Pixel) und besteht aus einer Encoder-Decoder-Architektur mit Skip-Connections (Abb. ??). Die Trainingsbilder wurden mit den in Tabelle ?? spezifizierten Techniken augmentiert, was 16848 Bilder für die Harnblase und 15936 Bilder für das Rektum ergab.

Während der Validierung wurden für jedes Bild im Validierungsset folgende Metriken berechnet: Dice-Koeffizient, Präzision, Recall und Hausdorff-Abstand. Bei leeren Modellvorhersagen ($\sum \text{Vorhersage} = 0$) wurde der Hausdorff-Abstand als NaN gewertet, um verzerrte Ergebnisse zu vermeiden, während Dice, Präzision und Recall entsprechend der binären Klassifikationslogik berechnet wurden. Die Ergebnisse auf dem Validierungsset wurden als Mittelwert $\pm$ Standardabweichung berichtet. Zusätzlich wurden für jeden Fold die Vorhersage mit dem niedrigsten Dice-Koeffizienten visuell analysiert, um systematische Fehlerquellen zu identifizieren.

Augmentation	Parameter
Rotation	-10° bis 10°
Horizontales Spiegeln	—
Rauschen	Gaußsches Rauschen, Varianz: 0,001
Verzerrung	Scherung: $-0,1$ bis $0,1$
Skalierung	$0,9$ bis $1,1$

Tabelle 1: Augmentationstechniken zur Verbesserung der Modellrobustheit.




Abbildung 1: Architektur des U-Net-Modells für die Segmentierung von kV-CBCT-Bildern. Der kontrahierende Pfad (links) extrahiert Merkmale, während der expansive Pfad (rechts) präzise Segmentierungsmasken erzeugt. Skip-Connections verbinden die Pfade zur Erhaltung hochauflösender Details.

3 Ergebnisse

Die Segmentierungsleistung wurde anhand des Dice-Koeffizienten, Präzision, Recall und der Hausdorff-Distanz (HD) auf den Validierungsdaten bewertet. Der Füllungszustand wird bewertet, indem die Höhe der binären Segmentierungsmasken in Pixeln gemessen wird und mit den Ground-Truth-Masken verglichen wird.

Organ	Dice-Wert (Mittel $\pm$ SD)	Präzision	Recall	Hausdorff-Distanz (px, Mittel $\pm$ SD)
Harnblase	0,9149 $\pm$ 0,0852	0,8974	0,9454	9,1419 $\pm$ 9,0216
Rektum	0,7848 $\pm$ 0,1641	0,8019	0,7958	11,5230 $\pm$ 10,5643

Tabelle 2: Segmentierungsmetriken auf Validierungsdaten (aggregiert über 5-Fold-Kreuzvalidierung).


Die hohen Dice-Werte, Präzision und Recall sowie moderaten Hausdorff-Distanzen zeigen eine zuverlässige Segmentierung, wobei die Harnblase präziser segmentiert wurde als das Rektum, was auf dessen größere anatomische Variabilität zurückzuführen ist. Die Verlustkurven (Abb. ??) zeigen, dass beide Modelle eine stabile Konvergenz erreichen nach ca. 50 Epochen erreichen.

Die Segmentierungsleistung wird weiter durch Abbildung ?? und ?? illustriert, die rohe sagittale Schnitte, Ground-Truth-Masken und Modellvorhersagen für jeweils 6 Patienten (3 mit akzeptablen Dice Werten, sowie die 3 mit den niedrigsten Dice Werten) in den Validierungssets für die Harnblasen- und Rektummodelle gezeigt. Für die Harnblase (Abb. ??) sieht man ein Fehler in dem Ground-Truth Maske bei P132 (dritte Reihe, mittleres Panel) als Ursache für den niedrigen Dice Wert. Beim P050 ist der Kontrast schlecht - evtl. hat der Patient gehustet während der Aufnahme, und die Kontrast zwischen Harnblase und Darm ist gering, ebenfalls beim Patient P116. Für das Rektum (Abb. ??) sind die Ground-Truth Masken augenscheinlich korrekt, auch in den 3 Fällen schlechter Dice Werte. Beim Pat. P037 findet das Modell auch ein Anteil des Rektums oberhalb der Ground-Truth Maske, was den Dice Wert verringert, aber klinisch sinnvoll ist. Bei Patient P052 ist das Rektum kaum abgebildet in der Ground-Truth Maske, und vom Modell nicht erkannt. Beim Patient P129 ist die Modellvorhersage ggf. genauer an die anatomische Realität angepasst als die Ground-Truth Maske, trotz Dice Wert von 0,62.


4 Diskussion

Die Methode ermöglicht eine präzise Segmentierung von Harnblase und Rektum. Der Dice-Wert von $0,9149 \pm 0,0852$ für die Harnblase und $0,7848 \pm 0,1641$ für das Rektum, kombiniert mit Hausdorff-Distanzen von $9,1419 \pm 9,0216$ px bzw. $11,5230 \pm 10,5643$ px, liefert verlässliche Ergebnisse für den täglichen Einsatz in der IGRT. Die höhere Standardabweichung beim Rektum spiegelt dessen größere anatomische Variabilität wider (?). Die Verlustkurven (Abb. ??) zeigen, dass beide Modelle eine stabile Konvergenz erreichen.

Die trainierten Modelle können auf einem herkömmlichen Computer in wenigen Sekunden (nahezu in Echtzeit) ausgeführt werden, was eine Integration in den klinischen Alltag, etwa als Plugin für das RayStation- oder Aria-System,



(a) Trainings- und Validierungsverluste für das Harnblasenmodell.



(b) Trainings- und Validierungsverluste für das Rektummodell.

Abbildung 2: Verlauf der Trainings- und Validierungsverluste über Epochen für die Harnblase und das Rektum, die die Konvergenz der Modelle zeigen.




Abbildung 3: Harnblase: Panels für Validierungspatienten (P067 - Dice 0.97, P047 - Dice 0.96, P109 - 0.96, P132 - Dice 0.63, P050 - Dice 0.76, P116 - Dice 0.84). Links: Originalschnitt; Mitte: Ground Truth (grün); Rechts: Vorhersage (orange).






Abbildung 4: Rektum: Panels für Validierungspatienten (P122 - Dice 0.89, P051 - Dice 0.88, P112 - Dice 0.87, P037 - Dice 0.31, P052 - Dice 0.42, P129 Dice 0.62). Links: Originalschnitt; Mitte: Ground Truth (lila); Rechts: Vorhersage (pink).




(a) Metrikenverteilung für die Harnblase (Dice und Hausdorff).




(b) Metrikenverteilung für das Rektum (Dice und Hausdorff).


Abbildung 5: Verteilung der Validierungsmetriken für Harnblase und Rektum.



(a) Überlagerte Vorhersagen für gemeinsamen Validierungspatienten
(Patient 31, CBCT-ID:
1.2.752.243.1.1.20240423103417750.8780.50024).



(b) Überlagerte Vorhersagen für gemeinsamen Validierungspatienten
(Patient 51, CBCT-ID:
1.2.752.243.1.1.20240422134429818.1261.66127).



(c) Überlagerte Vorhersagen für gemeinsamen Validierungspatienten
(Patient 60, CBCT-ID:
1.2.752.243.1.1.20240423095943088.1745.41123).

Abbildung 6: Überlagerte Modellvorhersagen für Harnblase (gelb) und Rektum (blau) beispielhaft auf gemeinsamen Validierungspatienten angewandt.

ermöglicht und die tägliche Überprüfung der Organlage bzw Füllung praktikabel macht (?).

Zukünftig könnte die KI-basierte Segmentierung den Einsatz von Fiducials (z.B. Goldmarker für die IGRT) in bestimmten Fällen ersetzen, was Behandlungskosten und -zeit reduzieren sowie die mit invasiven Eingriffen verbundenen Risiken vermeiden könnte.

Eine Erweiterung des Modells auf das gesamte kV-CBCT-Volumen würde eine 3D-Segmentierung der Risikoorgane ermöglichen und die Genauigkeit sowie Robustheit der Methode steigern. Dies würde jedoch eine größere Datenbasis und mehr Rechenleistung erfordern. Da das Training auf einem Heimcomputer durchgeführt wurde, priorisierten wir 2D für Echtzeit-Inferenz (Sekunden pro Bild) und klinische Machbarkeit. Zukünftige Arbeiten könnten 3D-Modelle testen.

Im Vergleich zu Studien wie (?), die Dice-Werte von 0,90 für die Harnblase und 0,85- 0,90 für das Rektum auf CBCT-Daten berichten, zeigt unser Modell vergleichbare Leistung für die Harnblase (0,9149) und leicht geringere für das Rektum (0,7848), trotz der Herausforderung durch 2D-Schnitte. Die geringeren Dice-Werte für das Rektum könnten auf dessen komplexe Geometrie und Füllungsvariationen zurückzuführen sein, wie auch in (?) beobachtet.

Zukünftig könnte ein Multi-Organ-Modell getestet werden, um Überlappungen zu vermeiden und Konsistenz zu steigern (?). Ein Performance-Vergleich zwischen Einzel- und Multi-Organ-Modellen wäre wertvoll, allerdings ist die Inference für beide Organe einzeln Sekundenschnell und die VRAM Anforderungen gering. Somit können beide Modelle gleichzeitig auf Consumer-Hardware betrieben werden - wie in Abb. ?? gezeigt (Code dafür bei github einsehbar ?).

Theoretisch geplant ist eine Warnung an dem MTRA abzugeben bei einer signifikanten Abweichung der Modellvorhersage vom Ground-Truth Maske, z.Bsp. bei einer Höhenunterschied von > 10 Pixeln oder ein Flächenabweichung von $> 20\%$. Ob eine Höhenabweichung oder Flächenabweichung klinisch relevanter ist, und ab welcher Schwelle eine Warnung sinnvoll ist, müsste in zukünftigen Studien evaluiert werden.

Die Vorhersagen mit der groessten Abweichung vom Ground-Truth traten bei Organen mit schlechtem Kontrast durch Bildartefakte (z.B. Metallimplantate oder Bewegungsartefakte) oder unvollständige Organerfassung im CBCT, oder ungewöhnliche Anatomie. Dies deutet auf Einschränkungen in der Generalisierbarkeit des Modells hin, insbesondere bei extremen Füllungszuständen oder Bildartefakten. Die Analyse der Worst-Case-Beispiele zeigt, dass das Modell in solchen Fällen zu Über- oder Untersegmentierungen neigt. Einschränkungen der Methode umfassen auch die Abhängigkeit von konsistenten kV-CBCT-Parametern sowie den Informationsverlust durch die Dimensionsreduktion auf 2D. Der Datensatz ist homogen (keine Hochrisikoprofile, Daten von einem Gerät: Elekta Synergy-System, kV=120, mAs=650). Anatomische Besonderheiten wie postoperative Zustände, übermäßiges Darmgas oder Implantate waren selten; die Modell-Performance bei solchen Fällen war eingeschränkt, wie die Worst-Case-Analyse zeigt. Externe

Validierung ist essenziell, um die Generalisierungsfähigkeit zu prüfen. Zukünftige Arbeiten könnten Transfer Learning, erweiterte Augmentation oder ein nnU-Net einsetzen, um die Robustheit gegenüber variablen Geräteeigenschaften zu verbessern.

5 Schlussfolgerung

Die KI-basierte Methode automatisiert die 2D Segmentierung von Harnblase und Rektum effektiv und bietet Potenzial zur Verbesserung der Behandlungsqualität und Effizienz in der IGRT. Die hohen Performancemetriken und die stabile Konvergenz der Modelle (Abb. ??) untermauern die verlässliche Segmentierung der Risikoorgane, was den Einsatz in der klinischen Praxis unterstützt.

6 Literaturverzeichnis

Literatur

- Michela Antonelli, Annika Reinke, Spyridon Bakas, Keyvan Farahani, Annette Kopp-Schneider, Bennett A. Landman, Geert Litjens, Bjoern Menze, Olaf Ronneberger, Ronald M. Summers, Bram van Ginneken, Michel Bilello, Patrick Bilic, Patrick Christ, Richard K.G. Do, Marc J. Gollub, Stephan Golla, Jennifer Heckers, Henkjan Huisman, William R. Jarnagin, Maureen McHugo, Sandy Napel, Jennifer S. Pernicka, Kawal Rhode, Catalina Tobon-Gomez, Eugene Vorontsov, James A. Meakin, Sebastien Ourselin, Manuel Wiesenfarth, Pablo Arbeláez, Byeonguk Bae, Sihang Chen, Laura Daza, Jianjiang Feng, Baochun He, Fabian Isensee, Yuanfeng Ji, Fucang Jia, Ildoo Kim, Klaus Maier-Hein, Dorit Merhof, Akshay Pai, Beomhee Park, Mathias Perslev, Ramin Rezaiifar, Oliver Rippel, Ignacio Saraswat, Wei Shen, Jaemin Son, Christian Wachinger, Liansheng Wang, Yan Wang, Yingda Xia, Daguang Xu, Zhanwei Xu, Yichi Yang, Yujia Yu, Wei Zeng, Jiachen Zhang, Zhongchen Zheng, Kang Zhou, Jian Zhu, and Yingtong Zhu. The medical segmentation decathlon. *Nature Communications*, 13(1):4128, 2022. doi: 10.1038/s41467-022-30695-9.
- Mikel Byrne, Ben Archibald-Heeren, Yu Hu, Amy Teh, Rhea Beserminji, Eric Cai, Glenn Liu, Andrew Yates, Joel Rijken, Natalie Collett, and Tony Aland. Varian ethos online adaptive radiotherapy for prostate cancer: Early results of contouring accuracy, treatment plan quality, and treatment time. *Journal of Applied Clinical Medical Physics*, 23(1):e13479, 2022. doi: 10.1002/acm2.13479.
- Audrey Dang, Patrick A. Kupelian, Minsong Cao, Nzhde Agazaryan, and Amar U. Kishan. Image-guided radiotherapy for prostate cancer. *Translational Andrology and Urology*, 7(3):308–320, jun 2018. doi: 10.21037/tau.2017.12.37.

- Phillip M. Devlin, Robert A. Cormack, Caroline L. Holloway, and Alexandra J. Stewart. *Brachytherapy: Applications and Techniques*. Demos Medical Publishing, New York, NY, 2 edition, 2015. ISBN 978-1620700822.
- Nadia Di Muzio, Claudio Fiorino, Cesare Cozzarini, Filippo Alongi, Sara Broggi, Paola Mangili, Giorgio Guazzoni, Riccardo Valdagni, Riccardo Calandrino, and Ferruccio Fazio. Phase i-ii study of hypofractionated simultaneous integrated boost with tomotherapy for prostate cancer. *International Journal of Radiation Oncology Biology Physics*, 74(2):392–398, jun 2009. doi: 10.1016/j.ijrobp.2008.08.038.
- Sara Junius, Karin Haustermans, Barbara Bussels, Raymond Oyen, Bianca Vanstraelen, Tom Depuydt, Jan Verstraete, Steven Joniau, and Hendrik Van Poppel. Hypofractionated intensity modulated irradiation for localized prostate cancer, results from a phase i/ii feasibility study. *Radiation Oncology*, 2:29, 2007. doi: 10.1186/1748-717X-2-29.
- P. Kupelian, T. Willoughby, A. Mahadevan, T. Djemil, G. Weinstein, S. Jani, C. Enke, T. Solberg, N. Flores, D. Liu, D. Beyer, and L. Levine. Multi-institutional clinical experience with the calypso system in localization and continuous, real-time monitoring of the prostate gland during external radiotherapy. *International Journal of Radiation Oncology Biology Physics*, 67(4): 1088–1098, 2007. doi: 10.1016/j.ijrobp.2006.10.026.
- Lawrence B. Marks, Ellen D. Yorke, Andrew Jackson, Randall K. Ten Haken, Louis S. Constine, Avraham Eisbruch, Soren M. Bentzen, Jiho Nam, and Joseph O. Deasy. Use of normal tissue complication probability models in the clinic. *International Journal of Radiation Oncology Biology Physics*, 76(3): S10–S19, 03 2010. doi: 10.1016/j.ijrobp.2009.07.1754.
- Kazuyuki Numakura, Mizuki Kobayashi, Yumina Muto, Hiromi Sato, Yuya Sekine, Ryuta Sobu, Yu Aoyama, Yoshiko Takahashi, Syuhei Okada, Hajime Sasagawa, Shintaro Narita, Satoshi Kumagai, Yuki Wada, Naoko Mori, and Tomonori Habuchi. The current trend of radiation therapy for patients with localized prostate cancer. *Current Oncology*, 30(9):8092–8110, 2023. doi: 10.3390/curroncol30090587. URL <https://doi.org/10.3390/curroncol30090587>.
- Lorenzo Radici, Cristina Piva, Valeria Casanova Borca, Domenico Cante, Silvio Ferrario, Marina Paolini, Luigi Cabras, Edoardo Petrucci, Pietro Franco, Maria Rosa La Porta, and Massimo Pasquino. Clinical evaluation of a deep learning cbct auto-segmentation software for prostate adaptive radiation therapy. *Clinical and Translational Radiation Oncology*, 47, 2024. doi: 10.1016/j.ctro.2024.100793.
- Md. Eshmam Rayed, S.M. Sajibul Islam, Sadia Islam Niha, Jamin Rahman Jim, Md Mohsin Kabir, and M.F. Mridha. Deep learning for medical image segmentation: State-of-the-art advancements and challenges. *Informatics in Medicine Unlocked*, 2024. doi: 10.1016/j.imu.2024.101504.

- Peter Rhone. A number of tools and documentation for cbct image segmentation during prostate cancer treatment. https://github.com/peterrhone/dicom_sqlite, 2025. Software repository for AI tools in radiation oncology.
- Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. *arXiv*, 2015.
- Kenneth B. Salomon. An efficient point-in-polygon algorithm. *Computers Geosciences*, 4(2):173–178, 1978. ISSN 0098-3004. doi: [https://doi.org/10.1016/0098-3004\(78\)90085-7](https://doi.org/10.1016/0098-3004(78)90085-7). URL <https://www.sciencedirect.com/science/article/pii/0098300478900857>.
- Eli Stevens, Luca Antiga, and Thomas Viehmann. *Deep Learning with PyTorch*. Manning Publications, Shelter Island, NY, 2020. URL https://isip.piconepress.com/courses/temple/ece_4822/resources/books/Deep-Learning-with-PyTorch.pdf.
- Philip D. H. Wall, Robert L. Carver, and Jonas D. Fontenot. An improved distance-to-dose correlation for predicting bladder and rectum dose-volumes in knowledge-based vmat planning for prostate cancer. *Physics in Medicine & Biology*, 63(1):015035, 2018. doi: 10.1088/1361-6560/aa9a30.
- S. Wang, W. Tang, H. Luo, F. Jin, and Y. Wang. The role of image-guided radiotherapy in prostate cancer: A systematic review and meta-analysis. *Clinical and Translational Radiation Oncology*, 38:81–89, 2022. doi: 10.1016/j.ctro.2022.10.006.
- Jakob Wasserthal, Hanns-Christian Breit, Manfred T. Meyer, Maurice Pradella, Daniel Hinck, Alexander W. Sauter, Tobias Heye, Daniel T. Boll, Joshy Cyriac, Shan Yang, Michael Bach, and Martin Segeroth. Totalsegmentator: Robust segmentation of 104 anatomic structures in ct images. *Radiology: Artificial Intelligence*, 5(5):e230024, 2023. doi: 10.1148/ryai.230024.
- L.G.M. Zwart, F. Ong, L.A. Ten Asbroek, E.B. van Dieren, S.A. Koch, A. Bhananie, E. de Wit, and J.J. Dasselhaar. Cone-beam computed tomography-guided online adaptive radiotherapy is feasible for prostate cancer patients. *Physics and Imaging in Radiation Oncology*, 22:98–103, 2022. doi: 10.1016/j.phro.2022.04.008.