

KI-basierte IGRT mit 2D-bildgeführtem Dose Tracking täglicher Conebeam-CTs zur Bewertung der Prostatalage, Füllung von Rektum und Harnblase bei definitiver Radiotherapie des Prostatakarzinoms

Peter Rhone, Dipl.-Phys.¹, Saskia Spautz, MSc^{2,3,*},
Annika Schlamann, MD^{2,3}, Thomas Kuhnt, MD, Prof.^{2,3},
Franziska Nägler, MD^{2,3,**}

¹Klinik für Strahlentherapie und Radioonkologie, Heinrich-Braun-Klinikum Zwickau,

²Klinik und Poliklinik für Strahlentherapie, Universitätsklinikum Leipzig

³Mitteldeutsches Krebszentrum (CCCC), Partnerstandort Leipzig

* geteilte Erstautorschaft ** Seniorautorin

8. April 2025

Zusammenfassung

Hintergrund: Es wird eine Methode zur automatischen Erkennung von Harnblase und Rektum in täglichen Cone-Beam-CTs (kV-CBCTs) für die bildgesteuerte Strahlentherapie (IGRT) vorgestellt.

Methoden: Mediale sagittale Schnitte wurden mittels künstlicher Intelligenz (KI) segmentiert, um die Organlage sowie die Füllungszustände von Rektum und Harnblase bei der definitiven Radiotherapie des Prostatakarzinoms zu bewerten.

Ergebnisse: Das Modell wurde mit Daten von 131 Patienten trainiert und validiert mit jeweils 5 kV-CBCTs pro Patient. Die Ergebnisse zeigen eine hohe Segmentierungsleistung mit mittleren Dice-Werten von etwa 0,98 für Harnblase und Prostata-PTV sowie 0,95 für das Rektum.

Zusammenfassung: Die KI-basierte Methode kann die Überprüfung von Organlage und -füllung effektiv automatisieren und bietet Potenzial zur Verbesserung der Behandlungsqualität und Effizienz in der IGRT.

Schlüsselworte: Segmentierung, Prostata, Risikoorgane, Deep Learning, Medizinische Bildgebung, Cone-Beam-CT, CBCT, Strahlentherapie, Bildgesteuerte Strahlentherapie, Künstliche Intelligenz

1 Einleitung

Bei der definitiven Bestrahlung von Prostatakarzinomen niedrigen und mittleren Risikos kann eine perkutane Radiotherapie in Normfraktionierung, moderater Hypofraktionierung oder Ultrahypofraktionierung angewendet werden [Numakura et al., 2023, Junius et al., 2007, Di Muzio et al., 2009]. Dabei wird eine Gesamtdosis in tägliche Fraktionen verabreicht.

Interfraktionelle Variabilität durch Änderungen der Füllungszustände oder Organbewegungen im Beckenbereich kann OARs wie Harnblase und Rektum unerwünscht hohen Dosen aussetzen, was die akute oder chronische Toxizität erhöhen kann [Devlin et al., 2015].

Um diese Toxizitäten zu minimieren, ist ein zentraler Schritt in der modernen Strahlentherapie die Verifizierung der genauen Position des Tumors und der umliegenden Risikoorgane (OARs) vor jeder Fraktion mittels bildgesteuerter Strahlentherapie (IGRT) [Kupelian et al., 2007, Wang et al., 2022]. Es gibt verschiedene Methoden zur IGRT, z. B. Cone-Beam-CTs (CBCT) oder in die Prostata implantierte Fiducials (Goldmarker) in Kombination mit planaren Röntgenbildern [Dang et al., 2018]. Die Verifizierung der OAR-Füllungszustände ist jedoch nur mit CBCT möglich. Damit können variierende Füllungen und Bewegungen berücksichtigt und korrigiert werden, etwa eine unzureichend gefüllte Harnblase oder ein luftgefülltes Rektum, um das Einhalten von Dosis-Constraints wie $V_{65} < 50\%$ für die Harnblase sicherzustellen [Wall et al., 2018].

Online-adaptive Strahlentherapie passt täglich diese Veränderungen an, erfordert jedoch erheblichen Zeit- und Personalaufwand (15–35 Minuten pro Fraktion mit Facharzt und Medizinphysikexperten), was in Hochdurchsatz-Kliniken kaum umsetzbar ist [Byrne et al., 2022]. Häufig wird daher nur ein Offline-Review durchgeführt, bei dem Abweichungen erst nachträglich erkannt werden.

Inspiziert von Fortschritten in der medizinischen Bildsegmentierung, entwickeln wir eine KI-basierte Methode zur Teilautomatisierung der online-adaptiven Therapie, um die Lage und Füllung der Risikoorgane in täglichen CBCT-Aufnahmen effizienter zu überwachen und die Behandlungsqualität zu verbessern.

2 Methoden

Zwischen dem 01.07.2019 und dem 31.01.2024 wurden retrospektiv 131 Patienten mit Prostatakarzinom niedrigen bis mittleren Risikos ausgewählt, die eine definitive, moderat hypofraktionierte Radiotherapie (25 Fraktionen mit simultan-integriertem Boost, 58–68 Gy) erhielten, in Anlehnung an die Schema von [Di Muzio et al., 2009]. Einschlusskriterien waren cT1a–cT2b, PSA ≤ 20 ng/ml und Gleason-Score ≤ 7 ; Patienten mit Hochrisikoprofil oder Fernmetastasen wurden ausgeschlossen. Eine schriftliche Einwilligung zur anonymen Datenverwendung liegt vor.

Für jeden Patienten wurden ein Planungs-CT (PL-CT) und 5 kV-CBCTs aus dem RayStation-System (Versionen 10B–12A) anonymisiert extrahiert [Zwart et al., 2022]. Strukturen (Prostata-PTV, Harnblase, Rektum) wurden manuell von einem Medizophysiker konturiert und von einem Facharzt überprüft. Ein selbst entwickeltes Python-Programm (*sqlite_dicom2.py*) [Rhone, 2025] konvertierte DICOM-Daten in Volumina, extrahierte drei mediale sagittale 2D-Schnitte pro kV-CBCT – zentral durch die Symphyse sowie je einer links und rechts – und erstellte Binärmasken mittels *scipy.ndimage.ConvexHull*. Die Ausgaben (Patienten-ID, DICOM-Serie, Schnitte, Masken, Schnittnummer) wurden in eine SQLite-Datenbank gespeichert. Ein zweites Programm (*sqlite_viewer.py*) [Rhone, 2025] ermöglichte visuelle Kontrolle und Datenbereinigung.

Bilder wurden vorverarbeitet (Ausschluss ungewöhnlicher Größen, Normalisierung der Pixelintensität). Insgesamt entstanden ca. 2100 Bilder pro Organ (3 Schnitte $\times$ 5 kV-CBCTs $\times$ 131 Patienten), davon ca. 1700 fürs Training und ca. 400 für die Validierung, mit patientendisjunkten Datensätzen. Die Trainingsbilder wurden augmentiert, was ca. 9000 Bilder ergab, um die Modellrobustheit zu verbessern [Ronneberger et al., 2015, Pereira et al., 2016, Shorten and Khoshgoftaar, 2019]. Die verwendeten Augmentationstechniken sind in Tabelle 1 aufgeführt.

Augmentation	Parameter
Rotation	-45° bis 45°
Horizontales Spiegeln	Keine
Rauschen	Gaußsches Rauschen, Varianz: 0,001
Verzerrung	Scherung: $-0,1$ bis $0,1$

Tabelle 1: Augmentationstechniken zur Verbesserung der Modellrobustheit.

Ein U-Net-basiertes Convolutional Neural Network (CNN) Ronneberger et al. [2015] wurde mit PyTorch trainiert, um kV-CBCT-Bilder zu segmentieren (siehe Abb. 1). Das Modell verarbeitet mittelsagittale CT-Schnitte und besteht aus einer Encoder-Decoder-Architektur mit Skip-Connections, die hochauflösende Merkmale aus dem Encoder mit den aufwärtsgeführten Decoder-Ausgaben kombinieren, um präzise Organbegrenzungen, wie die der Harnblase, zu erhalten. Der kontrahierende Pfad (Encoder) umfasst vier Blöcke, die jeweils aus zwei 3×3 -Faltungen mit ReLU-Aktivierung und einem 2×2 -Max-Pooling bestehen; die Faltungen extrahieren lokale Merkmale wie Kanten oder Texturen, wobei Padding verwendet wird, um die räumlichen Dimensionen innerhalb der Blöcke zu erhalten, bevor das Max-Pooling die Dimensionen schrittweise halbiert. Die Anzahl der Feature-Kanäle (z. B. 64, 128, 256 im Encoder) gibt die Anzahl der gelernten Merkmalskarten an, was die Fähigkeit des Netzwerks widerspiegelt, komplexe Merkmale zu extrahieren. Der expansive Pfad (Decoder) verwendet transponierte Faltungen für das Upsampling, um die ursprünglichen Dimensionen wiederherzustellen, und erzeugt am Ende eine binäre Segmentierungsmaske.

Das Training wurde auf einer AMD RX 7900 XTX GPU mit 24 GB VRAM durchgeführt, beschleunigt durch den ROCm-Stack. Es wurde eine Lernrate von 10^{-4} mit dem Adam-Optimierer verwendet, und das Modell konvergierte nach 25 Epochen. Als Verlustfunktion diente die binäre Kreuzentropie mit Logits (BCEWithLogitsLoss). Nur CBCT-Daten wurden verwendet, um Konsistenz zu gewährleisten Litjens et al. [2017]. Die Trainingsdaten wurden in einem benutzerdefinierten `ImageDataset` als PyTorch-Tensoren organisiert, indem Pandas-Series in NumPy-Arrays gestapelt und anschließend in Tensoren umgewandelt wurden. Ein `DataLoader` (Batch-Größe 32, 4 Worker, `pin_memory=True`) wurde verwendet, um die Daten effizient zu laden. Während des Trainings wurden Bilder und Masken batchweise auf die GPU verschoben, der Verlust nach jedem Batch berechnet, rückpropagiert und optimiert. Die Trainingszeit betrug etwa 1 Stunde pro Organ.

3 Ergebnisse

Das U-Net-Modell wurde pro Organ auf etwa 400 Validierungsbilder getestet. Die Segmentierungsgenauigkeit zeigte folgende Dice-Koeffizienten, gemittelt über alle Validierungsbilder, siehe Tabelle 2:

Organ	Dice-Koeffizient	Standard-abweichung
Harnblase	0.9815	± 0.0126
Prostata	0.9789	± 0.0092
Rektum	0.9552	± 0.1021

Tabelle 2: Dice-Koeffizienten für die Segmentierung der Organe.

Die Volumina von Harnblase und Rektum wurden geschätzt. Diese Werte können mit den Volumina aus dem PL-CT verglichen werden, um die Füllungszustände zu bewerten.

Als „Ground Truth“ dienen die manuell erstellten Konturen, die von einem Facharzt überprüft wurden. Die Modellvorhersagen wurden visuell mit den Ground-Truth-Daten verglichen. Beispiele sind in den Abbildungen 2, 3 und 4 dargestellt.




Abbildung 2: Beispielhafte Segmentierung von Harnblase.

In Abbildung 2 deckt die Segmentierung die Harnblase augenscheinlich besser ab als die Ground Truth, die teilweise durch Segmentierungsartefakte kantig wirkt. Die Modellvorhersage ist glatter und umfasst die Harnblase vollständig. Die Blasenfüllung wurde in diesem Beispiel mit 150 ml geschätzt.




Abbildung 3: Beispielhafte Segmentierung von Prostata-PTV.

Die Modellvorhersage in Abbildung 3 deckt die Prostata-PTV sehr gut ab. Dies ist von fakultativem Interesse, da die PTV keine klar definierten anatomischen Grenzen wie die Harnblase aufweist. Dennoch kann die tatsächliche PTV auf das CBCT eingeblendet werden, um die Dosierung an die Risikoorgane abzuschätzen.




Abbildung 4: Beispielhafte Segmentierung von Rektum.

Die Ergebnisse für das Rektum in Abbildung 4 sind ebenfalls zufriedenstellend, jedoch weniger präzise als bei Harnblase und Prostata-PTV. Dies zeigt sich auch im niedrigeren Dice-Koeffizienten und der höheren Standardabweichung. Die Rektumfüllung wurde in diesem Beispiel mit 300 ml geschätzt.

4 Diskussion

Die Methode ermöglicht eine präzise Segmentierung von Harnblase und Rektum. Der Dice-Wert von 0,9815 für Harnblase und 0,9789 für Prostata-PTV liefert verlässliche Ergebnisse für den täglichen Einsatz in der IGRT. Der Wert von $0,9552 \pm 0,1021$ für das Rektum ist ebenfalls akzeptabel, insbesondere in Verbindung mit der Visualisierung, wobei die höhere Standardabweichung dessen größere Variabilität widerspiegelt [Litjens et al., 2017].

Die trainierten Modelle können auf einem herkömmlichen Computer in wenigen Sekunden (nahezu in Echtzeit) ausgeführt werden, was eine Integration in den klinischen Alltag, etwa als Plugin für das RayStation- oder Aria-System, ermöglicht und die tägliche Überprüfung der Organlage praktikabel macht.

Zukünftig könnte die KI-basierte Segmentierung den Einsatz von Fiducials (z. B. Goldmarker für die IGRT) in bestimmten Fällen ersetzen, was Behandlungskosten und -zeit reduzieren sowie die mit invasiven Eingriffen verbundenen Risiken vermeiden könnte.

Eine Erweiterung des Modells auf das gesamte kV-CBCT-Volumen würde eine 3D-Segmentierung der Risikoorgane ermöglichen und die Genauigkeit sowie Robustheit der Methode steigern. Besonders nützlich wäre die direkte Messung der Organvolumina. Dies würde jedoch vermutlich eine größere Datenbasis und mehr Rechenleistung erfordern.

Einschränkungen der Methode umfassen die Abhängigkeit von konsistenten kV-CBCT-Parametern sowie die Ungenauigkeit durch den Informationsverlust bei der Dimensionsreduktion auf 2D. Zukünftige Arbeiten könnten Transfer Learning (TL) oder erweiterte Augmentation einsetzen, um die Robustheit gegenüber variablen Geräten zu verbessern.

Das in dieser Studie entwickelte 2D U-Net-Modell erzielt Dice-Werte, die die Ergebnisse von Isaksson et al. [Isaksson et al., 2023] übertreffen. Unsere Modelle erreichen mittlere Dice-Werte von 0,98 für Harnblase und Prostata-PTV sowie 0,95 für das Rektum – Werte, die eine sehr hohe Übereinstimmung mit den Referenzkonturen zeigen. Im Vergleich dazu untersuchten Isaksson et al. sechs Segmentierungsmethoden, darunter ein 2D U-Net, auf T2-gewichteten MRT-Bildern von 100 Patienten. Ihr bestes Modell, eine angepasste EfficientDet-Architektur, erreichte einen mittleren Dice-Wert von 0,914 für das gesamte 3D-Prostata-Volumen, während andere Modelle, einschließlich des 2D U-Nets, Werte zwischen 0,855 und 0,907 erzielten. Dieser Leistungsunterschied lässt sich auf mehrere Faktoren zurückführen. Erstens nutzten wir kV-CBCT-Daten, im Gegensatz zu Isakssons T2-MRT-Sequenzen, was eine bessere Anpassung an die spezifischen Bildmerkmale ermöglicht haben könnte. Zweitens basiert unser Modell auf einer größeren Trainingsdatenbasis – etwa 9000 augmentierte Bilder aus 1700 Originalen von 131 Patienten – verglichen mit Isakssons 100 Patienten (ebenfalls augmentiert). Drittens vereinfacht unsere Fokussierung auf 2D-Schnitte (mediale sagittale Ebenen) die Segmentierung im Vergleich zu Isakssons 3D-

Volumenansatz, der komplexer ist und höhere Anforderungen an die Datenbasis stellt. Entscheidend ist zudem, dass unsere Dice-Werte auf einer planaren 2D-Berechnung pro Schnitt basieren, während Isaksson et al. den Dice-Koeffizienten über das gesamte 3D-Volumen berechneten, was die Vergleichbarkeit einschränkt, da 3D-Berechnungen durch räumliche Variationen tendenziell niedrigere Werte liefern können.

5 Schlussfolgerung

Die KI-basierte Methode automatisiert die Überprüfung von Prostatalage und Organfüllung effektiv und bietet Potenzial zur Verbesserung der Behandlungsqualität und Effizienz in der IGRT. Die hohen Dice-Koeffizienten untermauern die verlässliche Segmentierung der Organe, was den Einsatz in der klinischen Praxis unterstützt.

6 Literaturverzeichnis

Literatur

- M. Byrne, B. Archibald-Heeren, Y. Hu, A. Teh, R. Beserminji, E. Cai, G. Liu, A. Yates, J. Rijken, N. Collett, and T. Aland. Varian ethos online adaptive radiotherapy for prostate cancer: Early results of contouring accuracy, treatment plan quality, and treatment time. *Journal of Applied Clinical Medical Physics*, 23(1):e13479, 2022.
- Audrey Dang, Patrick A. Kupelian, Minsong Cao, Nzhde Agazaryan, and Amar U. Kishan. Image-guided radiotherapy for prostate cancer. *Translational Andrology and Urology*, 7(3):308–320, jun 2018. ISSN 2223-4691. doi: 10.21037/tau.2017.12.37. PMID: 30050792, PMCID: PMC6043755.
- Phillip M. Devlin, Robert A. Cormack, Caroline L. Holloway, and Alexandra J. Stewart. *Brachytherapy: Applications and Techniques*. Demos Medical Publishing, New York, NY, 2 edition, 2015. ISBN 978-1620700822.
- N. Di Muzio, C. Fiorino, C. Cozzarini, F. Alongi, S. Broggi, P. Mangili, G. Guazzoni, R. Valdagni, R. Calandrino, and F. Fazio. Phase i-ii study of hypofractionated simultaneous integrated boost with tomotherapy for prostate cancer. *International Journal of Radiation Oncology*Biophysics*, 74(2):392–398, June 2009. doi: 10.1016/j.ijrobp.2008.08.038. URL <https://doi.org/10.1016/j.ijrobp.2008.08.038>. Epub 2008 Dec 4.
- Lars Johannes Isaksson, Matteo Pepa, Paul Summers, Mattia Zaffaroni, Maria Giulia Vincini, Giulia Corrao, Giovanni Carlo Mazzola, Marco Rondoni, Giuliana Lo Presti, Sara Raimondi, Sara Gandini, Stefania Volpe, Za-

- harudin Haron, Sarah Alessi, Paola Pricolo, Francesco Alessandro Mistretta, Stefano Luzzago, Federica Cattani, Gennaro Musi, Ottavio De Cobelli, Marta Cremonesi, Roberto Orecchia, Giulia Marvaso, Giuseppe Petralia, and Barbara Alicja Jereczek-Fossa. Comparison of automated segmentation techniques for magnetic resonance images of the prostate. *BMC Medical Imaging*, 23(1):32, 2023. doi: 10.1186/s12880-023-00974-y. URL <https://doi.org/10.1186/s12880-023-00974-y>.
- S. Junius, K. Haustermans, B. Bussels, et al. Hypofractionated intensity modulated irradiation for localized prostate cancer, results from a phase i/ii feasibility study. *Radiation Oncology*, 2:29, 2007. doi: 10.1186/1748-717X-2-29. URL <https://doi.org/10.1186/1748-717X-2-29>.
- P. Kupelian, T. Willoughby, A. Mahadevan, T. Djemil, G. Weinstein, S. Jani, C. Enke, T. Solberg, N. Flores, D. Liu, D. Beyer, and L. Levine. Multi-institutional clinical experience with the calypso system in localization and continuous, real-time monitoring of the prostate gland during external radiotherapy. *International Journal of Radiation Oncology*Biophysics*, 67(4): 1088–1098, 2007.
- Geert Litjens, Thijs Kooi, Babak Ehteshami Bejnordi, Arnaud Arindra Adiyoso Setio, Francesco Ciompi, Mohsen Ghahfoorian, Jeroen A.W.M. van der Laak, Bram van Ginneken, and Clara I. Sánchez. A survey on deep learning in medical image analysis. *Medical Image Analysis*, 42:60–88, 2017. doi: 10.1016/j.media.2017.07.005.
- Kazuyuki Numakura, Mizuki Kobayashi, Yumina Muto, Hiromi Sato, Yuya Sekine, Ryuta Sobu, Yu Aoyama, Yoshiko Takahashi, Syuhei Okada, Hajime Sasagawa, Shintaro Narita, Satoshi Kumagai, Yuki Wada, Naoko Mori, and Tomonori Habuchi. The current trend of radiation therapy for patients with localized prostate cancer. *Current Oncology*, 30(9):8092–8110, 2023. doi: 10.3390/curroncol30090587. URL <https://doi.org/10.3390/curroncol30090587>.
- Sérgio Pereira, Adriano Pinto, Victor Alves, and Carlos A. Silva. Data augmentation for improving deep learning in image segmentation. *Proc. SPIE*, 9785: 97850M, 2016.
- Peter Rhone. dicom_sqlite: Software tools for ai in radiation oncology. https://github.com/peterrhone/dicom_sqlite, 2025. Software Repository for this project.
- Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. *arXiv*, 2015.
- Connor Shorten and Taghi M. Khoshgoufar. A survey on image data augmentation for deep learning. *Journal of Big Data*, 6:60, 2019.
- Philip D. H. Wall, Robert L. Carver, and Jonas D. Fontenot. An improved distance-to-dose correlation for predicting bladder and rectum dose-volumes

- in knowledge-based vmat planning for prostate cancer. *Physics in Medicine Biology*, 63(1):015035, 2018. doi: 10.1088/1361-6560/aa9a30. URL <https://doi.org/10.1088/1361-6560/aa9a30>.
- S. Wang, W. Tang, H. Luo, F. Jin, and Y. Wang. The role of image-guided radiotherapy in prostate cancer: A systematic review and meta-analysis. *Clinical and Translational Radiation Oncology*, 38:81–89, 2022.
- L.G.M. Zwart, F. Ong, L.A. Ten Asbroek, E.B. van Dieren, S.A. Koch, A. Bhawanie, E. de Wit, and J.J. Dasselhaar. Cone-beam computed tomography-guided online adaptive radiotherapy is feasible for prostate cancer patients. *Physics and Imaging in Radiation Oncology*, 22:98–103, 2022.