

KI-basierte IGRT mit 2D-bildgeführtem Dose Tracking täglicher Conebeam-CTs zur Bewertung der Prostatalage, Füllung von Rektum und Harnblase bei definitiver Radiotherapie des Prostatakarzinoms

Peter Rhone, Dipl.-Phys., Prof. Dr. med. Thomas Kuhnt,
Dr. med. Franziska Nägler

11. März 2025

Zusammenfassung

Es wird eine Methode zur automatischen Erkennung von Harnblase und Rektum in täglichen Cone-Beam-CTs (kV-CBCTs) für die bildgesteuerte Strahlentherapie (IGRT) vorgestellt. Mediale sagittale Schnitte – zentral durch die Symphyse sowie links und rechts davon – wurden mittels künstlicher Intelligenz (KI) segmentiert, um die Organlage sowie die Füllungszustände von Rektum und Harnblase bei der definitiven Radiotherapie des Prostatakarzinoms zu bewerten. Das Modell wurde mit Daten von 131 Patienten trainiert und validiert (jeweils 5 CBCTs pro Patient). Die Ergebnisse zeigen eine hohe Segmentierungsgenauigkeit mit Dice-Koeffizienten von etwa 0,98 für Harnblase und Prostata-PTV sowie 0,95 für das Rektum.

1 Einleitung

Bei der definitiven Bestrahlung von Prostatakarzinomen niedrigen und mittleren Risikos werden in unserer Einrichtung kurative Dosen von 68 Gy in moderater Hypofraktionierung appliziert [Kuhnt and Nägler, 2024]. Intrafraktionelle Variabilität, wie Füllungszustände oder Organbewegungen, kann dazu führen, dass Risikoorgane wie Harnblase und Rektum unerwünscht hohe Dosen erhalten, was die akute oder chronische Toxizität erhöhen kann [Kupelian et al., 2007, Marks et al., 2010]. Die bildgesteuerte Strahlentherapie (IGRT) mit Cone-Beam-CTs

(CBCTs) verifiziert die Organlagen vor jeder Fraktion. Jedoch erschweren variierende Füllungen – etwa eine schlecht gefüllte Harnblase oder ein luftgefülltes Rektum – das Einhalten von Dosis-Constraints wie $V_{65} < 50\%$ für die Harnblase [Wang et al., 2022, Marks et al., 2010]. Online-adaptive Strahlentherapie ermöglicht eine tägliche Anpassung an diese Veränderungen, erfordert jedoch erheblichen Personalaufwand (15–35 Minuten pro Fraktion) [Byrne et al., 2022], was in Hochdurchsatz-Kliniken kaum umsetzbar ist. Häufig wird nur ein Offline-Review durchgeführt, bei dem Abweichungen erst nachträglich erkannt werden. Diese Studie entwickelt eine KI-basierte Methode zur teilweisen Automatisierung der online-adaptiven Therapie, inspiriert von Fortschritten in der medizinischen Bildsegmentierung [Litjens et al., 2017], um die Prostatalage und Organfüllung effizienter zu überwachen und die Behandlungsqualität zu verbessern.

2 Methoden

Zwischen dem 01.07.2019 und dem 31.01.2024 wurden retrospektiv 131 Patienten mit Prostatakarzinom niedrigen bis mittleren Risikos ausgewählt, die eine definitive, moderat hypofraktionierte Radiotherapie (25 Fraktionen, 58–68 Gy) erhielten [Kuhnt and Nägler, 2024]. Einschlusskriterien waren cT1a–cT2b, PSA ≤ 20 ng/ml und Gleason-Score ≤ 7 ; Patienten mit Hochrisikoprofil oder Fernmetastasen wurden ausgeschlossen. Eine schriftliche Einwilligung zur anonymen Datenverwendung liegt vor.

Für jeden Patienten wurden ein Planungs-CT (PL-CT) und 5 kV-CBCTs aus dem RayStation-System (Versionen 10B–12A) anonymisiert extrahiert [Zwart et al., 2022]. Strukturen (Prostata-PTV, Harnblase, Rektum u.a.) wurden manuell von einem Medizinphysiker konturiert und von einem Facharzt überprüft. Ein selbst entwickeltes Python-Programm (*sqlite_dicom2.py*) Rhone [2025] konvertierte DICOM-Daten in Volumina, extrahierte drei mediale sagittale 2D-Schnitte pro CBCT – eine zentrale Schicht durch die Symphyse sowie je eine links und rechts davon – und generierte Binärmasken der Konturen mittels der *ConvexHull* Funktion aus dem *SciPy*-Bibliothek. Die Ausgaben (Patientennummer, DICOM-Serie, Schnittbilder, Maske, Schnittnummer) wurden in eine SQLite-Datenbank gespeichert. Ein zweites Sonderprogramm (*sqlite_viewer.py*) Rhone [2025] ermöglichte die visuelle Überprüfung und Datenbereinigung.

Die Bilder wurden präprozessiert (Entfernung von Bildern ungewöhnlicher Größen, Normalisierung der Pixeldaten). Insgesamt entstanden pro Organ ca. 2100 Bilder (3 Schnitte $\times$ 5 CBCTs $\times$ 131 Patienten), wovon etwa 1700 für das Training und etwa 400 für die Validierung genutzt wurden. Patienten dessen Bilder für das Training genutzt wurden, wurden aus dem Validierungsdatensatz ausgeschlossen. Zur Qualitätssteigerung wurden die 1700 Trainingsbilder durch Augmentation vervielfältigt – zufällige Rotation, Spiegelung, Zerrung, und Rauschen – wodurch etwa 9000 Bilder generiert wurden, eine bewährte Methode zur Verbesserung der Modellrobustheit in der Bildsegmentierung [Ronneberger et al., 2015, Pereira et al., 2016, Shorten and Khoshgoftaar, 2019].

Ein Convolutional Neural Network (CNN) basierend auf U-Net [Ronneber-

ger et al., 2015] wurde mit PyTorch trainiert, beschleunigt durch den ROCm-Stack auf einer AMD RX 7900 XTX GPU mit 24 GB VRAM. Das Modell besteht aus einer Encoder-Decoder-Architektur mit Faltungsblöcken (jeweils zwei 3×3 -Faltungen mit ReLU-Aktivierung) und transponierten Faltungen für die Upsampling-Schichten. Es wurde mit einer Lernrate von 10^{-4} und dem Adam-Optimierer über 25 Epochen trainiert, wobei die binäre Kreuzentropie mit Logits (*BCEWithLogitsLoss*) als Verlustfunktion diente. Nur CBCT-Daten wurden zum Training verwendet, um Konsistenz zu gewährleisten [Litjens et al., 2017]. Die Trainingsdaten wurden in einem benutzerdefinierten *ImageDataset* als PyTorch-Tensoren (aus Pandas-Series gestapelt) organisiert und mit einem *DataLoader* (Batch-Größe 32, 4 Worker, *pin_memory=True*) geladen. Während des Trainings wurden Bilder und Masken batchweise auf die GPU verschoben, der Verlust nach jedem Batch rückpropagiert und optimiert. Die Trainingszeit betrug ca. 1 Stunde pro Organ.

Das Blasenvolumen wurde grob geschätzt, indem Höhe und Breite der Blasenmaske in der mittleren sagittalen Ebene gemessen und das Volumen eines prolaten Sphäroids berechnet wurden. Für das Rektum wurde das Volumen eines Zylinders zur Schätzung herangezogen.

3 Ergebnisse


Das U-Net-Modell wurde pro Organ auf etwa 400 Validierungsbilder getestet. Die Segmentierungsgenauigkeit zeigte folgende Dice-Koeffizienten, gemittelt über alle Validierungsbilder:

Organ	Dice-Koeffizienten	Standardabweichung
Harnblase	0.9815	± 0.0126
Prostata PTV	0.9789	± 0.0092
Rektum	0.9552	± 0.1021


Tabelle 1: Dice-Koeffizienten und Standardabweichungen für verschiedene Organe.

Die Volumina von Harnblase und Rektum wurden geschätzt. Diese Werte können mit den Volumina aus dem PL-CT verglichen werden, um die Füllungszustände zu bewerten.

Als „Ground Truth“ dienten die manuell erstellten Konturen, die von einem Facharzt überprüft wurden. Die Modellvorhersagen wurden visuell mit den Ground-Truth-Daten verglichen. Beispiele sind in den Abbildungen 1, 2 und 3 dargestellt.




(a) Beispielhafte Segmentierung von Harnblase. Rot: Ground Truth, Gelb: Vorhersage, Orange: Übereinstimmung.



(b) Beispielhafte Segmentierung von Harnblase. Links: Originalbild, Mitte: Ground Truth, Rechts: Vorhersage des Modells.

Abbildung 1: Gesamtübersicht der Segmentierungsergebnisse für die Harnblase.

In Abbildung 1b deckt die Segmentierung die Harnblase augenscheinlich besser ab als die Ground Truth, die teilweise durch Segmentierungsartefakte kantig wirkt. Die Modellvorhersage ist glatter und umfasst die Harnblase vollständig. Die Blasenfüllung wurde in diesem Beispiel mit 150 ml geschätzt.




(a) Beispielhafte Segmentierung von Prostata PTV. Gelb: Ground Truth, Dunkelblau: Vorhersage, Blaugrün: Übereinstimmung.



(b) Beispielhafte Segmentierung von Prostata PTV. Links: Originalbild, Mitte: Ground Truth, Rechts: Vorhersage des Modells.

Abbildung 2: Gesamtübersicht der Segmentierungsergebnisse für die Prostata PTV.

Die Modellvorhersage in Abbildung 2b deckt die Prostata-PTV sehr gut ab. Dies ist von fakultativem Interesse, da die PTV keine klar definierten anatomischen Grenzen wie die Harnblase aufweist. Dennoch kann die tatsächliche PTV auf das CBCT eingeblendet werden, um die Dosierung an die Risikoorgane abzuschätzen.



(a) Beispielhafte Segmentierung von Rektum. Gelb: Ground Truth, Dunkelbraun: Vorhersage, Hellbraun: Übereinstimmung.



(b) Beispielhafte Segmentierung von Rektum. Links: Originalbild, Mitte: Ground Truth, Rechts: Vorhersage des Modells.

Abbildung 3: Gesamtübersicht der Segmentierungsergebnisse für das Rektum.

Die Ergebnisse für das Rektum in Abbildung 3b sind ebenfalls zufriedenstellend, jedoch weniger präzise als bei Harnblase und Prostata-PTV. Dies zeigt sich auch im niedrigeren Dice-Koeffizienten und der höheren Standardabweichung. Die Rektumfüllung wurde in diesem Beispiel mit 300 ml geschätzt.

4 Diskussion

Die Methode ermöglicht eine präzise Segmentierung von Harnblase und Rektum. Der Dice-Koeffizient von 0,98 für Harnblase und Prostata-PTV liefert verlässliche Ergebnisse für den täglichen Einsatz. Der Wert von 0,95 für das Rektum ist ebenfalls akzeptabel, insbesondere in Verbindung mit der Visualisierung. Die höhere Standardabweichung von 0,1 für das Rektum spiegelt dessen größere Variabilität wider [Litjens et al., 2017]. Die trainierten Modelle können auf einem handelsüblichen Computer in wenigen Sekunden (nahezu in Echtzeit) ausgeführt werden, was eine Integration in den klinischen Alltag, etwa als Plugin für das RayStation-System, ermöglicht.

Eine Erweiterung des Modells auf das gesamte kV-CBCT-Volumen würde eine 3D-Segmentierung der Risikoorgane ermöglichen und die Genauigkeit sowie Robustheit der Methode steigern. Besonders nützlich wäre die direkte Messung

der Organvolumina. Dies würde jedoch vermutlich eine größere Datenbasis und mehr Rechenleistung erfordern.

Einschränkungen der Methode umfassen die Abhängigkeit von konsistenten CBCT-Parametern sowie die Ungenauigkeit durch den Informationsverlust bei der Dimensionsreduktion auf 2D.

Zukünftige Arbeiten könnten Transfer-Learning oder erweiterte Augmentation einsetzen, um die Robustheit gegenüber variablen Geräten zu verbessern.

5 Schlussfolgerung

Die KI-basierte Methode automatisiert die Überprüfung von Prostatalage und Organfüllung effektiv und bietet Potenzial zur Verbesserung der Behandlungsqualität und Effizienz in der IGRT. Die hohen Dice-Koeffizienten untermauern die Möglichkeit eines Einsatzes ohne Fiducials (z. B. Goldmarker) in der Prostata, wie derzeit üblich. Sie bildet die Grundlage für breitere klinische Anwendungen nach weiterer Validierung.

6 Danksagung

Wir danken der Klinik für Strahlentherapie am Universitätsklinikum Leipzig für die Datenbereitstellung und technische Unterstützung sowie Prof. Dr. med. Thomas Kuhnt und Dr. med. Franziska Nägler für die fachliche Betreuung und Saskia Spautz für die Aufbereitung der Patientendaten.

7 Literaturverzeichnis

Literatur

M. Byrne, B. Archibald-Heeren, Y. Hu, A. Teh, R. Beserminji, E. Cai, G. Liu, A. Yates, J. Rijken, N. Collett, and T. Aland. Varian ethos online adaptive radiotherapy for prostate cancer: Early results of contouring accuracy, treatment plan quality, and treatment time. *Journal of Applied Clinical Medical Physics*, 23(1):e13479, 2022.

Thomas Kuhnt and Franziska Nägler. Ki-basierte igrt mit 2d-bildgeführtem dose tracking täglicher conebeam-cts zur bewertung der prostatalage, füllung von rektum und harnblase bei definitiver radiotherapie des prostatakarzinoms. Research proposal, feb 2024. Version 1.0, Antrag- Strahlentherapie, Interner Studienname: 2D-Dose Tracking Prostatakarzinom, Dated 29 February 2024.

P. Kupelian, T. Willoughby, A. Mahadevan, T. Djemil, G. Weinstein, S. Jani, C. Enke, T. Solberg, N. Flores, D. Liu, D. Beyer, and L. Levine. Multi-institutional clinical experience with the calypso system in localization and

- continuous, real-time monitoring of the prostate gland during external radiotherapy. *International Journal of Radiation Oncology*BiologicalPhysics*, 67(4): 1088–1098, 2007.
- Geert Litjens, Thijs Kooi, Babak Ehteshami Bejnordi, Arnaud Arindra Adiyoso Setio, Francesco Ciompi, Mohsen Ghafoorian, Jeroen A.W.M. van der Laak, Bram van Ginneken, and Clara I. Sánchez. A survey on deep learning in medical image analysis. *Medical Image Analysis*, 42:60–88, 2017. doi: 10.1016/j.media.2017.07.005.
- E-mail: marks@med.unc.edu Marks, Lawrence B., Ellen D Yorke, Andrew Jackson, Randall K Ten Haken, Louis S Constine, Avraham Eisbruch, Soren M Bentzen, Jiho Nam, and Joseph O Deasy. Use of normal tissue complication probability models in the clinic. *International Journal of Radiation Oncology, Biology and Physics*, 76(3), 03 2010. ISSN ISSN 0360-3016. doi: 10.1016/j.ijrobp.2009.07.1754. URL <https://www.osti.gov/biblio/21372125>.
- Sérgio Pereira, Adriano Pinto, Victor Alves, and Carlos A. Silva. Data augmentation for improving deep learning in image segmentation. *Proc. SPIE*, 9785: 97850M, 2016.
- Peter Rhone. dicom_sqlite: Software tools for ai in radiation oncology. https://github.com/peterrhone/dicom_sqlite, 2025. Software Repository for this project.
- Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. *arXiv*, 2015.
- Connor Shorten and Taghi M. Khoshgftaar. A survey on image data augmentation for deep learning. *Journal of Big Data*, 6:60, 2019.
- S. Wang, W. Tang, H. Luo, F. Jin, and Y. Wang. The role of image-guided radiotherapy in prostate cancer: A systematic review and meta-analysis. *Clinical and Translational Radiation Oncology*, 38:81–89, 2022.
- L.G.M. Zwart, F. Ong, L.A. Ten Asbroek, E.B. van Dieren, S.A. Koch, A. Bhawanie, E. de Wit, and J.J. Dasselhaar. Cone-beam computed tomography-guided online adaptive radiotherapy is feasible for prostate cancer patients. *Physics and Imaging in Radiation Oncology*, 22:98–103, 2022.